Benchmark LLM Ollama – Équipe G22 Auralis

Nov 10, 2026 · @jody

Choix des modèles open source exécutés via Ollama pour Sillage, le radar buzz ou tendance de G22 – Auralis (thème 3). Le LLM doit surtout produire des informations **fiables et structurées** — ingrédients, pays, dates, catégories extraits des documents — puis expliquer les prédictions du modèle de score, uniquement à partir des sources.

Équipe G22 – Auralis · Data : Roua CHERNI, Joseph-Bernardin AFANOU, Tahiri ROSSAINA · Repo : github.com/Hetic-Hackathon-Givaudan-2026-Groupe-22/example-rag

Recommandation

Quatre candidats à départager par un même test : **qwen3.5:4b** comme candidat principal, encadré par qwen3.5:2b (le plus petit suffisant ?), ministral-3:3b (une autre famille fait-elle mieux ?) et qwen3.5:9b (le plus grand vaut-il son coût ?). Embeddings : **bge-m3**.

- **Pourquoi Qwen3.5 plutôt que Qwen3 :** famille sortie en février–mars 2026, déclinée en 2B, 4B et 9B, multimodale, 201 langues et dialectes, licence Apache 2.0, contexte natif de 262K tokens.
- **Pourquoi Ministral 3 3B :** éviter de dépendre d'une seule famille ; modèle Mistral sorti en décembre 2025, Apache 2.0, texte et image, intéressant pour un contexte francophone et international.
- **Matériel :** GPU Google Colab possible mais non garanti, et 19 s par réponse mesurées sur un PC sans carte graphique avec le plus petit modèle. D'où des modèles compacts quantifiés Q4_K_M, testés du plus petit au plus grand.
- **Point technique :** les Qwen3.5 « réfléchissent » par défaut (balises `<think>`), ce qui rallonge les réponses et peut casser une sortie JSON. Pour l'extraction, désactiver ce mode (option `think: false` dans l'appel Ollama) et le mesurer séparément pour l'explication.
- **Biais à gérer :** un LLM récent connaît déjà l'issue des tendances passées (Dalgona, matcha). Le score vient du modèle discriminatif à date figée ; le LLM n'extrait et n'explique qu'à partir des extraits fournis, sur des cas anonymisés.

Les candidats

Tags Ollama exacts, quantification Q4_K_M. Taille = téléchargement ; la mémoire réellement nécessaire est plus haute (contexte, calculs).

Modèle (tag Ollama)	Taille	Contexte	Entrées	Licence	Question à laquelle il répond
qwen3.5:2b-q4_K_M	1,9 Go	256K	Texte, image	Apache 2.0	Quel niveau minimal suffit pour extraire ingrédients, pays et dates ?
ministral-3:3b-instruct-2512-q4_K_M	3,0 Go	256K	Texte, image	Apache 2.0	À ressources proches, une autre famille fait-elle mieux ?
qwen3.5:4b-q4_K_M	3,3 Go	256K	Texte, image	Apache 2.0	**Candidat principal** : qualité suffisante sans passer à 9B ?
qwen3.5:9b-q4_K_M	6,6 Go	256K	Texte, image	Apache 2.0	Le gain sur plusieurs documents et contradictions justifie-t-il le coût ?
qwen2.5:1.5b	1,0 Go	32K	Texte	Apache 2.0	Référence : modèle du repo, déjà mesuré

Écartés : qwen3.6 (18 Go minimum) et gemma4 (4,6 Go dès la plus petite version, sans avantage attendu pour l'extraction), trop lourds sans GPU garanti.

Modèles d'embeddings comparés

Changer de modèle d'embeddings impose `python clean.py` puis `python ingest.py` : deux modèles ne produisent pas des vecteurs compatibles.

Modèle	Taille	Contexte	Langues	Pour nous
nomic-embed-text	0,27 Go	2K	Non précisé	Modèle du repo ; référence de comparaison
embeddinggemma	0,6 Go	2K	100+	Alternative légère multilingue
qwen3-embedding:0.6b	0,64 Go	32K	100+	Passages longs ; la version 8b de cette famille était annoncée n° 1 du classement MTEB multilingue en juin 2025
bge-m3	1,2 Go	8K	100+	**Recommandé**

Méthode de sélection

Cinq filtres appliqués dans l'ordre, puis la licence :

1. **Adéquation au métier :** extraire saveurs, pays, dates et catégories de produits, dans des documents multilingues.

2. **Fiabilité en RAG :** répondre à partir des sources, dire quand l'information est absente, produire un JSON valide.
3. **Compatibilité matérielle :** tourner avec Ollama sur un portable sans carte graphique ou sur un GPU Colab.
4. **Efficacité :** versions quantifiées, taille justifiée par un gain mesuré.
5. **Valeur expérimentale :** chaque modèle répond à une question différente du benchmark.
6. **Licence :** compatible avec un usage en entreprise (Apache 2.0 pour les quatre candidats).

Protocole : deux tests complémentaires

Mêmes conditions pour chaque modèle : température 0,2, contexte 4 096 tokens, **mode réflexion désactivé** (usage réel de Sillage ; les modèles qui ne le gèrent pas sont appelés sans), préchauffage pour ne pas compter le chargement. Les deux scripts sont dans le repo.

	Test A — Fidélité RAG	Test B — Extraction métier
Ce qu'il mesure	Répondre uniquement à partir des passages retrouvés, sans inventer	Extraire ingrédients, pays et années en JSON, comme le fera Sillage
Jeu de test	15 questions sur le corpus du repo : 5 factuelles, 5 de raisonnement multi-chapitres, 5 dont la réponse est absente	10 textes courts du domaine annotés à la main (Dubai chocolate, matcha, Dalgona, ube, swicy, yuzu, gochujang, cacao, lait d'avoine) + 1 piège sans ingrédient ; 4 questions sur une fiche tendance dont 2 sans réponse
Indicateurs	Bonnes réponses, refus corrects, couverture des chapitres retrouvés, temps médian, tokens/s ; relecture humaine des réponses	F1 par champ (ingrédients, pays, années), taux de JSON valide, refus corrects, temps moyen, tokens/s
Script	`benchmark_ollama.py` + `benchmark_questions.json` (racine du repo)	`benchmark/bench_ollama.py`

Règle de décision : on retient le plus petit modèle dont le F1 d'extraction est à moins de 5 points du meilleur, qui refuse correctement toutes les questions sans réponse et répond en moins de 30 s sur la machine de démo.

Résultats

Mesures sur un PC Windows sans carte graphique (10 novembre 2026). Les cases « à mesurer » sont remplies en lançant les deux scripts.

Test A — Fidélité RAG (15 questions)

Modèle	Bonnes réponses /10	Refus corrects /5	Temps médian	Tokens/s
qwen2.5:1.5b	1/1 mesurée (F01 : « Éclair »)	À mesurer	19 s (premier appel)	À mesurer
qwen3.5:2b	À mesurer	À mesurer	À mesurer	À mesurer
ministral-3:3b	À mesurer	À mesurer	À mesurer	À mesurer
qwen3.5:4b	À mesurer	À mesurer	À mesurer	À mesurer

Test B — Extraction métier (10 textes)

Modèle	F1 ingrédients	F1 pays	F1 années	JSON valide	Temps moyen
qwen2.5:1.5b	À mesurer	À mesurer	À mesurer	À mesurer	À mesurer
qwen3.5:2b	À mesurer	À mesurer	À mesurer	À mesurer	À mesurer
ministral-3:3b	À mesurer	À mesurer	À mesurer	À mesurer	À mesurer
qwen3.5:4b	Test préliminaire (1 texte) : ingrédients et années justes	Dubaï (ville) classé en pays	Justes	1/1	≈ 13 s modèle chargé (7,6 tokens/s)

Décision provisoire : qwen3.5:4b, seul modèle déjà testé en extraction, produit un JSON correct en environ 13 s une fois chargé, sous le seuil de 30 s. À confirmer par les deux tests complets ; qwen3.5:2b reste le repli si les temps se dégradent. Le prompt d'extraction impose désormais de convertir une ville en pays.

Sources

- Bibliothèque Ollama, pages des modèles et tags consultées le 10 novembre 2026 : qwen2.5, qwen3, qwen3.5, qwen3.6, llama3.2, gemma3, gemma4
- Embeddings : liste Ollama, nomic-embed-text, embeddinggemma, qwen3-embedding, bge-m3
- Repo example-rag (hmicn) : README, config.py, api.py
- Cours « Les bases absolues » et capsule RAG de Michael Nguyen (Educentre), 10 novembre 2026
- Ollama — tags qwen3.5 et tags ministral-3, consultés le 10 novembre 2026
- Qwen3.5-4B sur Hugging Face : licence, 201 langues, contexte, mode réflexion
- Mistral 3 et Ministral 3 sous Apache 2.0 (TestingCatalog, 2 décembre 2025)