Benchmark LLM Ollama – Équipe G22 Auralis

10 novembre 2026 · @jody

Choix des modèles open source exécutés via Ollama pour **Sillage**, le radar « buzz ou tendance » de G22 – Auralis (thème 3). Le LLM doit surtout produire des informations **fiables et structurées** — ingrédients, pays, dates et catégories extraits des documents — puis expliquer les prédictions du modèle de score, uniquement à partir des sources.

Équipe G22 – Auralis · Data : Roua CHERNI, Joseph-Bernardin AFANOU, Tahiri ROSSAINA

Repo : github.com/Hetic-Hackathon-Givaudan-2026-Groupe-22/example-rag

Recommandation

Quatre candidats à départager par un même protocole : **qwen3.5:4b** comme candidat principal, accompagné de **qwen3.5:2b** (quel est le plus petit modèle suffisant ?), **ministral-3:3b** (une autre famille fait-elle mieux ?) et **qwen3.5:9b** (le gain de qualité justifie-t-il le coût ?). **Embeddings du RAG de référence : nomic-embed-text.** bge-m3 reste une alternative à évaluer, pas un choix validé.

• **Pourquoi Qwen3.5 plutôt que Qwen3 :** famille sortie en février–mars 2026, déclinée en 2B, 4B et 9B, multimodale, 201 langues et dialectes, licence Apache 2.0, contexte annoncé de 262K tokens.

• **Pourquoi Ministral 3 3B :** éviter de dépendre d'une seule famille ; modèle Mistral sorti en décembre 2025, Apache 2.0, texte et image, intéressant en contexte francophone et international.

• **Matériel :** GPU Google Colab possible mais non garanti ; une réponse RAG mesurée en 19 s sur un PC sans GPU avec qwen2.5:1.5b. D'où des modèles compacts quantifiés en Q4_K_M.

• **Point technique :** pour les Qwen3.5, tester le mode réflexion désactivé (**think: false**) sur les tâches d'extraction structurée ; mesurer séparément son éventuel apport à l'explication.

• **Biais à gérer :** un LLM récent peut déjà connaître l'issue des tendances historiques (Dalgona, matcha). Le score doit venir d'un modèle prédictif à date figée ; les explications du LLM doivent être limitées aux extraits fournis.

État des travaux

Présélection argumentée et deux essais exploratoires documentés. Les autres modèles et la grille complète de mesures restent à comparer. Les mesures réelles sont reproduites page 4, sans extrapolation.

Les candidats

Tags Ollama utilisés ou prévus, quantification Q4_K_M pour les quatre candidats. Les tailles indiquées sont celles des fichiers téléchargés, pas les besoins totaux de mémoire.

Modèle (tag Ollama)	Taille	Contexte*	Entrées	Hypothèse à tester
qwen3.5:2b-q4_K_M	1,9 Go	256K	Texte, image	Quel niveau minimal suffit pour extraire ingrédients, pays et dates ?
ministral-3:3b-instruct-2512-q4_K_M	3,0 Go	256K	Texte, image	À ressources proches, une autre famille fait-elle mieux ?
qwen3.5:4b-q4_K_M	3,3 Go	256K	Texte, image	Candidat principal : qualité suffisante sans passer à 9B ?
qwen3.5:9b-q4_K_M	6,6 Go	256K	Texte, image	La qualité multi-documents justifie-t-elle le coût ?
qwen2.5:1.5b	1,0 Go	32K	Texte	Référence du dépôt : premier essai RAG mesuré.

* Contexte annoncé par les fiches de modèles ; le contexte réellement utilisé dépend des paramètres et des ressources. Les quatre candidats sont annoncés sous licence Apache 2.0.

Écartés de cette présélection : qwen3.6 et gemma4, jugés trop coûteux pour les ressources envisagées. Ce choix est un arbitrage matériel, **pas** une conclusion de performance obtenue par test.

Modèles d’embeddings envisagés

Ne pas changer le modèle d’embeddings pendant le benchmark LLM : **nomic-embed-text** est celui de **example-rag**. Tout changement de modèle exige de reconstruire l’index avec **clean.py** puis **ingest.py**.

Embeddings	Taille	Contexte	Langues	Statut
nomic-embed-text	0,27 Go	2K	Non précisé	Utilisé dans le dépôt ; référence
embeddinggemma	0,6 Go	2K	100+	Alternative à tester
qwen3-embedding:0.6b	0,64 Go	32K	100+	Alternative à tester ; contexte long
bge-m3	1,2 Go	8K	100+	Candidat à tester, non validé

Méthode de sélection

Filtres : **(1)** adéquation au métier, **(2)** fidélité RAG et JSON valide, **(3)** compatibilité PC/Colab, **(4)** efficacité des ressources, **(5)** intérêt expérimental d’une comparaison inter-familles ; **(6)** vérification des licences.

Protocole de benchmark

Le protocole prévu vise à comparer **les mêmes données, les mêmes prompts et les mêmes paramètres** pour chaque modèle : température 0,2 et mode réflexion désactivé pour l'extraction. L'index d'embeddings et la recherche documentaire doivent rester identiques dans la comparaison RAG.

1. Extraction structurée (20 textes) : textes réels courts (articles, fiches produit Open Food Facts, posts), annotés manuellement : ingrédients, pays, dates, catégories. Sortie JSON imposée. Mesurer précision, rappel et F1 par champ, plus taux de JSON valide.

2. Fidélité RAG (10 questions) : interroger **/ask** sur le même corpus, dont 4 questions sans réponse dans les sources. Compter les réponses justes et les abstentions correctes ; relever les inventions.

3. Explication (5 cas anonymisés) : donner un score prédictif fourni (courbe résumée, présence de produits, prix matière) ; notation de 1 à 5 par deux relecteurs, selon les sources citées, la clarté et l'absence d'inventions.

4. Ressources : enregistrer les temps de réponse, chargement, mémoire et machine utilisée (PC sans GPU ou Colab GPU). Les temps provenant de matériels différents ne doivent pas être interprétés comme une comparaison directe des modèles.

Règle de décision envisagée

Choisir le plus petit modèle dont le F1 d'extraction est à moins de 5 points du meilleur, qui n'invente pas sur les questions sans réponse et respecte le seuil visé de 30 secondes sur la machine de démonstration. **Cette règle ne peut pas encore être appliquée** : les mesures comparables du protocole complet ne sont pas disponibles.

Points de vigilance

• **Un résultat sur un seul texte ne constitue pas un score F1.** Une bonne réponse ponctuelle ne démontre pas que le modèle généralise.

• **Une erreur « Dubaï = pays »** révèle une limite d'extraction géographique ; elle doit être comptabilisée dans l'évaluation, même si le JSON est valide.

• **Un essai RAG et un essai d'extraction ne sont pas comparables.** Pour départager les modèles, répéter le même scénario sur chacun.

• **Les timings CPU et GPU doivent rester séparés.** Noter la quantification, la longueur de prompt, le matériel et les conditions de chargement.

Traçabilité

Les résultats présentés page suivante reprennent **uniquement** les observations inscrites dans le rapport original du 10 novembre 2026. Les autres cellules portent explicitement « non mesuré » ou « planifié ».

Résultats disponibles au 10 novembre 2026

Essais exploratoires : un cas RAG pour la baseline et un texte d'extraction pour Qwen3.5 4B. Les protocoles complets prévus page 3 restent à exécuter.

Modèle	Environnement	Observation vérifiée	Mesure / statut
qwen2.5:1.5b (référence)	PC Windows, sans GPU	1 question RAG : réponse correcte. F1, JSON et abstention non évalués.	19 s sur **une** question
qwen3.5:2b	Non précisé	Pas de résultat fourni.	Test planifié
ministral-3:3b	Non précisé	Pas de résultat fourni.	Test planifié
qwen3.5:4b	PC Windows, sans GPU	1 texte : ingrédients et dates corrects, mais « Dubaï » (ville) classé comme pays. JSON valide (1/1), **extraction partiellement correcte**. F1 non calculable.	23 s dont 9,7 s de chargement ; ≈ 13 s modèle chargé ; 7,6 tokens/s
qwen3.5:9b	GPU Colab envisagé	Pas de résultat fourni.	Test conditionné à la disponibilité du GPU

Décision provisoire

qwen3.5:4b demeure le candidat privilégié pour les prochains tests, et non un vainqueur démontré. Sur l'unique texte évalué, le modèle a produit un JSON valide avec des ingrédients et des dates corrects, mais a confondu une ville avec un pays. Le temps observé est d'environ 13 s hors chargement. La comparaison sur les 20 textes annotés, les questions RAG et les cinq cas d'explication reste nécessaire ; qwen3.5:2b est un candidat de repli à évaluer.

Script présent dans le dépôt : benchmark_ollama.py. Les mesures déclarées ci-dessus ne proviennent pas toutes d'un même protocole, et ne permettent pas de conclure à une supériorité statistique.

Sources mentionnées dans le rapport initial

Bibliothèque Ollama : qwen2.5, qwen3, qwen3.5, qwen3.6, llama3.2, gemma3, gemma4 ; tags qwen3.5 et ministral-3 (consultation du 10 novembre 2026).

Embeddings Ollama : nomic-embed-text, embeddinggemma, qwen3-embedding, bge-m3.

Dépôt example-rag (hmicn) : README, config.py, api.py ; cours « Les bases absolues » et capsule RAG de Michael Nguyen (Educentre), 10 novembre 2026.

Qwen3.5-4B sur Hugging Face (licence, langues, contexte, mode réflexion) ; Mistral 3 / Ministral 3 sous Apache 2.0 (TestingCatalog, 2 décembre 2025).